Discriminación y Clasificación de Estados Anémicos a partir de Biometría Hemática mediante Análisis Discriminante Lineal (LDA) en Ayacucho, 2026.

UNIVERSIDAD NACIONAL SAN CRISTOBAL DE HUAMANGA

FACULTAD DE INGENIERÍA DE MINAS, GEOLOGÍA Y CIVIL

ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS

Asignatura: INTELIGENCIA ARTIFICIAL I (IS-484)

Integrantes:

Gutierrez Mendoza, Miguel Eduardo

Mallqui Sosa, Gian Carlos

Pretell Reymundo, Leydi Aneth

Ramos Lopez, Isaias

Torres Morales, Sem Cham

Villanueva Mayhua, Tedy Breslin

Docente: VILA HUAMAN, Eloy

Ayacucho – Perú

2026

ÍNDICE

RESUMEN v

ABSTRACT vi

INTRODUCCIÓN 7

I. CAPÍTULO I: ASPECTOS GENERALES DE LA INVESTIGACIÓN 7

1.1. Planteamiento del Problema 7

1.2. Formulación del Problema 7

1.3. Objetivo General 7

1.4. Objetivos Específicos 7

1.5. Justificación del Proyecto 7

1.6. Delimitación del Proyecto 7

1.7. Marco Teórico 7

1.8. Antecedentes de la Investigación 7

1.8.1. Antecedentes internacionales 7

1.8.2. Antecedentes nacionales 9

II. CAPÍTULO II: DESARROLLO DEL PROYECTO 13

2.1. Diagnóstico de la Situación Actual 13

2.2. Metodología de Trabajo 13

2.3. Desarrollo de la Propuesta 13

2.4. Resultados Obtenidos 13

2.5. Análisis de Resultados 13

III. CONCLUSIONES 14

IV. RECOMENDACIONES 15

V. BIBLIOGRAFÍA 16

FIGURAS

Figura 1 Línea de tiempo de los antecedentes revisados según técnica y fuente de datos 7

Tablas

Tabla 1 Síntesis de los antecedentes de la investigación 10

RESUMEN

La anemia en la primera infancia continúa siendo uno de los problemas de salud pública más persistentes del Perú: en 2024 afectó a más de un tercio de las niñas y niños de 6 a 35 meses, con mayor incidencia en el área rural. Su diagnóstico habitual depende de la medición de hemoglobina, lo que exige una punción capilar y equipamiento que no siempre está disponible en los establecimientos de primer nivel. Ante ello, la presente investigación tuvo como objetivo construir un modelo de discriminación y clasificación de los estados anémicos en menores de cinco años mediante el Análisis Discriminante Lineal (LDA), empleando únicamente variables antropométricas, biológicas y socioeducativas, sin recurrir a la hemoglobina como predictor. El estudio, de enfoque cuantitativo y alcance predictivo, se desarrolló en Ayacucho a partir de los microdatos del módulo RECH6 de la Encuesta Demográfica y de Salud Familiar (ENDES) 2025, que reúne 19 298 registros. Como variable objetivo se utilizó el nivel de anemia (grave, moderada, leve y sin anemia) y como predictores se seleccionaron once variables: edad, peso, talla, cuatro puntajes Z de la OMS (talla/edad, peso/edad, peso/talla e IMC/edad), sexo, nivel y años de educación de la madre, y orden de nacimiento. Las variables directas de hemoglobina se excluyeron para evitar la fuga de información (*data leakage*). Tras depurar códigos de excepción y valores fuera de los rangos oficiales del INEI, se obtuvo un conjunto final de 16 476 registros, de los cuales el 34,5 % presentó algún grado de anemia (24,5 % leve, 9,9 % moderada y 0,1 % grave). Sobre esta base se estiman las funciones discriminantes y se evalúa su capacidad de clasificación mediante métricas de exactitud, sensibilidad y especificidad, cuyos resultados se detallan en el Capítulo II. Se espera que el modelo constituya una herramienta de tamizaje de bajo costo que contribuya a priorizar a la población infantil con mayor riesgo de anemia.

Palabras clave: anemia infantil, análisis discriminante lineal, aprendizaje automático, ENDES, antropometría, clasificación.

ABSTRACT

Early-childhood anemia remains one of Peru's most persistent public health problems: in 2024 it affected more than one third of children aged 6 to 35 months, with a higher burden in rural areas. Its diagnosis usually relies on hemoglobin testing, which requires a capillary blood sample and equipment that is not always available in primary care facilities. This study therefore aimed to build a model to discriminate and classify anemia levels in children under five using Linear Discriminant Analysis (LDA), relying solely on anthropometric, biological and socio-educational variables and deliberately excluding hemoglobin as a predictor. The research, quantitative in approach and predictive in scope, was carried out in Ayacucho using microdata from the RECH6 module of the 2025 Demographic and Family Health Survey (ENDES), comprising 19,298 records. Anemia level (severe, moderate, mild and no anemia) was used as the target variable, and eleven predictors were selected: age, weight, height, four WHO Z-scores (height-for-age, weight-for--age, weight-for-height and BMI-for-age), sex, mother's educational level and years of schooling, and birth order. Hemoglobin variables were excluded to prevent data leakage. After removing exception codes and values outside the official INEI ranges, the final dataset contained 16,476 records, 34.5% of which showed some degree of anemia (24.5% mild, 9.9% moderate and 0.1% severe). On this basis, discriminant functions are estimated and their classification performance is assessed through accuracy, sensitivity and specificity, as reported in Chapter II. The model is expected to serve as a low-cost screening tool that helps prioritize the children at greatest risk of anemia.

Keywords: childhood anemia, linear discriminant analysis, machine learning, ENDES, anthropometry, classification.

INTRODUCCIÓN

CAPÍTULO I: ASPECTOS GENERALES DE LA INVESTIGACIÓN

Planteamiento del Problema

Formulación del Problema

Objetivo General

Objetivos Específicos

Justificación del Proyecto

Delimitación del Proyecto

Marco Teórico

Antecedentes de la Investigación

La revisión de la literatura permitió identificar estudios que abordan la anemia desde dos perspectivas complementarias: por un lado, investigaciones epidemiológicas que describen sus factores asociados a partir de encuestas poblacionales y, por otro, trabajos que aplican técnicas de aprendizaje automático —entre ellas el análisis discriminante— para predecir o clasificar esta condición. A continuación se presentan los antecedentes internacionales y nacionales más pertinentes, ordenados cronológicamente, y en la Figura 1 se resume su evolución.

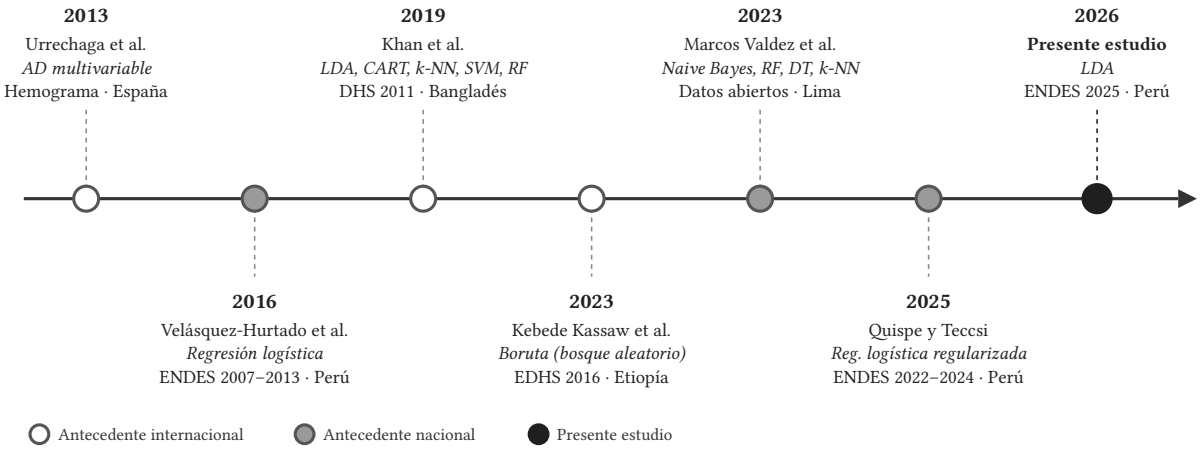
Nota. Elaboración propia a partir de los estudios citados en esta sección. AD = análisis discriminante; LDA = análisis discriminante lineal; RF = bosque aleatorio; DT = árbol de decisión.

Antecedentes internacionales

Urrechaga et al. (2013) evaluaron la utilidad del análisis discriminante multivariable para el diagnóstico diferencial de la anemia microcítica, con el propósito de distinguir la anemia ferropénica de los portadores de talasemia. Para ello entrenaron funciones discriminantes con un grupo de 480 pacientes, empleando como predictores parámetros del hemograma (recuento de eritrocitos, hemoglobina, volumen corpuscular medio, hemoglobina corpuscular media y amplitud de distribución eritrocitaria), y las validaron posteriormente en 628 casos consecutivos. Al separar las anemias de origen genético de las adquiridas bastó una sola función discriminante,

Figura 1

Línea de tiempo de los antecedentes revisados según técnica y fuente de datos



la cual clasificó correctamente al 87,9 % de los portadores de β-talasemia y al 83,3 % de los portadores de α-talasemia. Los autores concluyeron que las funciones discriminantes lineales construidas con datos rutinarios del hemograma constituyen un apoyo eficaz para orientar qué muestras requieren pruebas confirmatorias. Este trabajo respalda la pertinencia del LDA como técnica de clasificación en el ámbito hematológico.

Posteriormente, Khan et al. (2019) compararon el desempeño de diversos algoritmos de aprendizaje automático para predecir la anemia infantil en Bangladés, utilizando información de 2013 niños menores de cinco años procedente de la Encuesta Demográfica y de Salud de 2011. Entre los clasificadores evaluados se incluyeron el análisis discriminante lineal, los árboles de clasificación y regresión (CART), los *k* vecinos más cercanos, las máquinas de vectores de soporte, el bosque aleatorio y la regresión logística. El bosque aleatorio obtuvo el mejor rendimiento, con una exactitud de 68,53 %, una sensibilidad de 70,73 % y un área bajo la curva (AUC) de 0,686, superando a la regresión logística, que alcanzó 62,75 % de exactitud. Los autores sostienen que los métodos de aprendizaje automático pueden complementar a la regresión clásica cuando el objetivo principal es la predicción. Este antecedente resulta especialmente cercano a la presente

investigación, pues emplea una encuesta de diseño equivalente a la ENDES e incorpora el LDA como uno de los modelos de referencia.

En una línea similar, Kebede Kassaw et al. (2023) aplicaron un enfoque de aprendizaje automático para identificar los predictores de la anemia en menores de cinco años en Etiopía, a partir de un estudio transversal con 9501 niños de la Encuesta Demográfica y de Salud de 2016. Mediante el algoritmo Boruta, basado en bosques aleatorios, seleccionaron las variables más relevantes y hallaron que el número de hijos, la distancia al establecimiento de salud, la cobertura de seguro, la eliminación de heces del menor, el área de residencia, el índice de riqueza, el tipo de combustible para cocinar, el tamaño del hogar, la educación de la madre y la vacunación contra rotavirus figuraban entre los diez predictores más importantes. El estudio evidencia que los determinantes sociodemográficos y del entorno familiar —como la educación materna, considerada también en esta investigación— aportan información valiosa para anticipar la anemia sin recurrir a pruebas de laboratorio.

Antecedentes nacionales

En el contexto peruano, Velásquez-Hurtado et al. (2016) analizaron los factores asociados con la anemia en niños de 6 a 35 meses a partir de la ENDES 2007-2013. Mediante regresión logística multivariada, y considerando como anémicos a los menores con hemoglobina ajustada por altitud inferior a 11 g/dL, estimaron una prevalencia del 47,9 % e identificaron doce factores asociados. Entre los de carácter sociodemográfico destacaron residir fuera de Lima y Callao, pertenecer a un hogar de bajo nivel socioeconómico, tener una madre adolescente o con escasa educación y ser varón menor de 24 meses; entre los vinculados al cuidado materno-infantil, la ausencia de control prenatal en el primer trimestre, la falta de suplementación con hierro durante la gestación, el parto domiciliario, la anemia materna y la ausencia de tratamiento antiparasitario. Los autores concluyeron que la ENDES es una fuente idónea para caracterizar la anemia infantil.

Este estudio sustenta la selección de variables como la edad, el sexo y la educación de la madre en el presente trabajo.

Más adelante, Marcos Valdez et al. (2023) desarrollaron un modelo de aprendizaje automático para predecir la anemia en menores de cinco años a partir de su estado nutricional, aplicando un proceso de minería de datos sobre 138 369 registros provenientes de la Plataforma Nacional de Datos Abiertos, correspondientes a distritos de Lima. Tras las etapas de limpieza, reducción y transformación, aplicaron las pruebas F de ANOVA y chi-cuadrado para seleccionar diez variables predictoras, y compararon árboles de decisión, regresión logística, *k* vecinos más cercanos, bosque aleatorio y Naive Bayes. Este último obtuvo el mejor desempeño, con una sensibilidad del 74 %, una precisión del 43 % y una exactitud del 70 %. Los autores advirtieron que el desbalance entre clases condicionó los resultados, aspecto que también se presenta en la ENDES 2025, donde predominan los casos sin anemia.

Finalmente, Quispe Manrique & Teccsi Cerda (2025) construyeron un modelo predictivo del riesgo de anemia en niños menores de cinco años de distintas regiones del Perú utilizando la ENDES 2022-2024. A partir de 55 808 registros y de un proceso de ingeniería de características que generó 78 variables, compararon diversos algoritmos y encontraron que la regresión logística regularizada ofrecía el mejor equilibrio, con un AUC de 0,72 y una sensibilidad del 74,72 %. Los autores concluyeron que la anemia responde a desigualdades estructurales que trascienden la suplementación nutricional. Este antecedente confirma la viabilidad de emplear la ENDES con fines predictivos y muestra que los modelos lineales e interpretables alcanzan un rendimiento competitivo frente a alternativas más complejas.

La Tabla 1 sintetiza los aspectos metodológicos de los estudios revisados.

Nota. Elaboración propia. CART = árboles de clasificación y regresión; DT = árbol de decisión; k-NN = *k* vecinos más cercanos; NB = Naive Bayes; RF = bosque aleatorio; RL = regresión logística; SVM = máquina de vectores de soporte.

Tabla 1

Síntesis de los antecedentes de la investigación

Autor (año)	Fuente y muestra	Técnica principal	Resultado relevante
Urrechaga et al. (2013)	Hemogramas, 628 pacientes (España)	Análisis discriminante multivariable	87,9 % de β--talasémicos bien clasificados
Khan et al. (2019)	DHS 2011, 2013 niños (Bangladés)	LDA, CART, k-NN, SVM, RF, regresión logística	RF: exactitud 68,53 %
Kebede Kassaw et al. (2023)	EDHS 2016, 9501 niños (Etiopía)	Boruta (bosque aleatorio)	Diez predictores sociodemográficos
Velásquez-Hurtado et al. (2016)	ENDES 2007-2013 (Perú)	Regresión logística multivariada	Prevalencia 47,9 %; 12 factores
Marcos Valdez et al. (2023)	Datos abiertos, 138 369 registros (Lima)	DT, RL, k-NN, RF, Naive Bayes	NB: exactitud 70 %
Quispe Manrique & Teccsi Cerda (2025)	ENDES 2022-2024, 55 808 registros (Perú)	Regresión logística regularizada	AUC 0,72; sensibilidad 74,72 %

En conjunto, los antecedentes muestran que la anemia infantil puede anticiparse con un desempeño aceptable a partir de variables no hematológicas, y que los modelos lineales —como la regresión logística y el LDA— ofrecen resultados competitivos con la ventaja de ser interpretables. No obstante, en la revisión realizada no se identificaron estudios peruanos que apliquen el análisis discriminante lineal —propuesto originalmente por Fisher (1936) y sistematizado en obras de referencia como la de James et al. (2021)— para discriminar de forma simultánea los distintos

niveles de anemia con los datos más recientes de la ENDES. Este vacío cobra mayor relevancia tras la actualización de los puntos de corte de hemoglobina de la Organización Mundial de la Salud (World Health Organization, 2024), adoptada en el país mediante la RM 251-2024-MINSA, con la cual la prevalencia nacional en niños de 6 a 35 meses se estimó en 35,3 % para 2024, frente al 43,7 % obtenido con el criterio anterior (Instituto Nacional de Estadística e Informática, 2025). Lo expuesto justifica la presente investigación.

CAPÍTULO II: DESARROLLO DEL PROYECTO

Diagnóstico de la Situación Actual

Metodología de Trabajo

Desarrollo de la Propuesta

Resultados Obtenidos

Análisis de Resultados

CONCLUSIONES

RECOMENDACIONES

BIBLIOGRAFÍA

Fisher, R. A. (1936). The use of multiple measurements in taxonomic problems. *Annals of Eugenics*, *7*(2), 179-188. https://doi.org/10.1111/j.1469-1809.1936.tb02137.x

Instituto Nacional de Estadística e Informática. (2025). *Perú: Indicadores de resultados de los programas presupuestales, 2024 (Informe preliminar)*. https://proyectos.inei.gob.pe/endes/2024/ppr2/Indicadores_de_Resultados_de_los_Programas_Presupuestales_ENDES_2024.pdf

James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An introduction to statistical learning: With applications in R* (2.ª ed.). Springer. https://doi.org/10.1007/978-1-0716-1418-1

Kebede Kassaw, A., Yimer, A., Abey, W., Molla, T. L., & Zemariam, A. B. (2023). The application of machine learning approaches to determine the predictors of anemia among under five children in Ethiopia. *Scientific Reports*, *13*, 22919. https://doi.org/10.1038/s41598-023--50128-x

Khan, J. R., Chowdhury, S., Islam, H., & Raheem, E. (2019). Machine learning algorithms to predict the childhood anemia in Bangladesh. *Journal of Data Science*, *17*(1), 195-218. https://doi.org/10.6339/JDS.201901_17(1).0009

Marcos Valdez, A. J., Navarro Ortiz, E. G., Quinteros Peralta, R. E., Tirado Julca, J. J., Valentin Ricaldi, D. F., & Calderon Vilca, H. D. (2023). Machine learning for the prediction of anemia in children under 5 years of age by analyzing their nutritional status using data mining. *Computación y Sistemas*, *27*(3). https://doi.org/10.13053/CyS-27-3-4315

Quispe Manrique, M. C., & Teccsi Cerda, D. N. (2025). *Predicción de riesgo de anemia para niños menores a cinco años en regiones del Perú usando datos del INEI* [Tesis de licenciatura]. https://repositorioacademico.upc.edu.pe/handle/10757/689000

Urrechaga, E., Aguirre, U., & Izquierdo, S. (2013). Multivariable discriminant analysis for the differential diagnosis of microcytic anemia. *Anemia*, *2013*, 457834. https://doi.org/10.1155/2013/457834

Velásquez-Hurtado, J. E., Rodríguez, Y., Gonzáles, M., Astete-Robilliard, L., Loyola-Romaní, J., Vigo, W. E., & Rosas-Aguirre, Á. M. (2016). Factores asociados con la anemia en niños menores de tres años en Perú: análisis de la Encuesta Demográfica y de Salud Familiar, 2007-2013. *Biomédica*, *36*(2), 220-229. https://doi.org/10.7705/biomedica.v36i2.2896

World Health Organization. (2024). *Guideline on haemoglobin cutoffs to define anaemia in individuals and populations*. World Health Organization. https://www.who.int/publications/i/item/9789240088542